

PLAN DE DESPLIEGUE

MODELO DE DETECCIÓN DE FRAUDES

INTRODUCCIÓN:

Un banco quiere reemplazar el modelo de detección de fraudes en tarjetas de crédito. El nuevo modelo, entrenado con datos recientes, promete ser más preciso. Sin embargo, existe el riesgo de que el modelo bloquee compras legítimas (falsos positivos) o deje pasar fraudes reales (falsos negativos). El impacto en el negocio puede ser enorme: si se bloquean transacciones válidas, los clientes se quejan; si pasan fraudes, el banco pierde dinero.

OBJETIVO:

Diseñar un plan de despliegue completo para el nuevo modelo del Machine Learning que garantice:

- ↑ MAXIMIZAR SATISFACCIÓN
- ↓ MINIMIZAR RIESGOS

1 VALIDACIÓN PREVIA

Validación técnica

Medir falsos positivos y negativos en un dataset que representen transacciones reales y recientes.
Métricas de Machine learning: Precisión, Recall y F1.

Validación de negocio

Cuantificar el **impacto económico** esperado teniendo en cuenta posibles costos esperados desde los falsos positivos y falsos negativos.

3 MONITOREO

Métricas Operativas

Falsos positivos / negativos reales.
Tasa de fraude **detectado** vs **no detectado**.
Tiempo promedio de inferencia.
Costo estimado diario por errores.

Data Drift

Detectar cambios en la **distribución** de los datos de entrada.

Model Drift

Detectar degradación del modelo debido a cambios en la **relación** entre variables.

2 DESPLIEGUE

Se seguirá un plan de **2 etapas** con despliegue paralelo y gradual.

Fase 1: Shadow Deployment

Ambos modelos se ejecutan **simultáneamente**:

- El modelo antiguo toma las **decisiones** reales.
- Se **comparan** predicciones de ambos.

Fase 2: Canary Release

El **nuevo modelo** comienza a decidir sobre un **3%** de las transacciones reales menores a 1000 USD. La cobertura se **incrementa** en un 3% diariamente.

4 MEJORA CONTINUA

- Reentrenamientos trimestrales** con los datos más recientes y validación automática de performance.
- Incorporación de prácticas de **MLOps**.
- Pipeline CI/CD** de **ML** : automatización de pruebas y despliegue. .
- Gestión de **versiones** de datos, modelos y experimentos.
- Entornos **consistentes** y **escalables**.

ESTRATEGIA DE ROLLBACK

Se revierte **automáticamente** todo el tráfico al modelo anterior si y solo si los porcentajes de falsos positivos y / o negativos aumenta. Las medidas se basan en las quejas recibidas.

SEGURIDAD

- Anonimización de **datasets**.
- Monitoreo de **ataques**.
- Infraestructura** segura: NetworkPolicies en Kubernetes.
- Auditoría: **logs** de predicciones, accesos y modelos.

ROLES

- Equipo de Data Science
- Equipo MLOps
- Equipo de Riesgo
- Atención al Cliente

HERRAMIENTAS

Docker Kubernetes SageMaker MLflow GitLab EvidentlyAI Prometheus

CONCLUSIÓN

Desplegar el modelo de fraude en forma **gradual** (shadow + canary), con monitoreo y rollback, permite **reducir riesgos** y mantener el equilibrio entre **evitar fraudes** y no bloquear clientes legítimos.

REFERENCIAS

MLOps: Continuous delivery for machine learning
Kubernetes: Deployments
MLflow: Documentation
Canary: Google SRE (s.f.). Canary Releases and Deployment Safety. The Site Reliability Workbook.

4K2 - GRUPO 14 - INTEGRANTES

Jalile Francisco 99069
Marenchino Matías 97899
Giuliano Valentino 94819
Leonetti Fabrizio 95771
Suppo Laureano 99700

Kilic Haik 85246
Sanchez Camila 85669
Breitkopf Simon 86395
Rodeyro Nicolas 86537
Moyano Santiago 94003